

线性模型

- 基本形式

给定由 d 个属性描述的示例 $x = (x_1; x_2; \cdots; x_d)$, 其中 x_i 是 x 在第 i 个属性上的取值 , 线性模型试图学得一个通过属性的线性组合来进行预测的函数 , 即

$$f(x) = w_1 x_1 + w_2 x_2 + \cdots + w_d x_d + b$$

- 向量形式

$$f(x) = w^T x + b$$

单元线性回归

$$f(x) = wx_i + b, \text{ 使得 } f(x_i) \approx y_i$$

性能度量 :

$$(w^*, b^*) = \arg \min_{(w, b)} \sum_{i=1}^m (f(x_i) - y_i)^2 = \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx^i - b)^2$$

对 w 和 b 分别求偏导即可得到最优解

多元线性回归

$$f(x_i) = w^T x_i + b \text{ 使得 } f(x_i) \approx y_i, \text{ 其中 } x_i = (x_{i1}; x_{i2}; \cdots; x_{id})$$

把 w 和 b 吸收入向量形式 $\hat{w} = (w; b)$, 把数据集 D 表示为一个 $m \times (d + 1)$ 大小的矩阵 X , 有

$$X = \begin{bmatrix} x_{11} & a_{12} & \cdots & a_{1d} & 1 \\ a_{21} & a_{22} & \cdots & a_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{md} & 1 \end{bmatrix} = \begin{bmatrix} x_1^T & 1 \\ x_2^T & 1 \\ \vdots & \vdots \\ x_m^T & 1 \end{bmatrix}$$

标记写成向量形式 $y = (y_1; y_2; \cdots; y_m)$, 有

$$\hat{w}^* = \arg \min_{\hat{w}} (y - X\hat{w})^T (y - X\hat{w})$$

令 $E_{\hat{w}} = (y - X\hat{w})^T (y - X\hat{w})$, 对 \hat{w} 求导得到

$$\frac{\partial E_{\hat{w}}}{\partial \hat{w}} = 2X^T (X\hat{w} - y)$$

当上式为零可得 \hat{w} 最优解的闭式解。

最终得到多元线性回归模型为

$$f(\hat{x}_i) = \hat{x}_i^T (X^T X)^{-1} X^T y$$

广义线性模型

现实中不可能每次都能用线性模型进行拟合，需要对输出做空间的非线性映射，便可得到广义的线性模型，从线性到非线性

$$y = g^{-1}(w^T x + b)$$

线性判别分析 (LDA)

给定训练样例集，设法将样例投影到一条直线上，使得同类样例的投影点尽可能接近、异类样例的投影点尽可能远离；在对新样本进行分类时，将其投影到同样的这条直线上，再根据投影点的位置来确定新样本的类别。（监督降维技术）

$$\max J = \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \sum_0 w + w^T \sum_1 w} = \frac{w^T (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T w}{w^T (\sum_0 + \sum_1) w}$$

逻辑回归

用线性回归模型的预测结果去逼近真实标记的对数几率。实际上是一种分类学习方法。

对数几率函数

$$y = \frac{1}{1 + e^{-(w^T x + b)}}$$

变换为

$$\ln \frac{y}{1-y} = w^T x + b$$

多分类学习

- 多分类学习可在二分类基础上进行。将原问题拆分为多个二分类任务，然后每个二分类训练一个分类器，然后再进行集成获得最终的多分类结果。
- 拆分策略
 1. One vs One
 2. One vs Rest
 3. Many vs Many

类别不平衡问题

- 再放缩

$$\frac{y'}{1-y'} = \frac{y}{1-y} \times \frac{m^-}{m^+}$$

- 解决策略
 1. 欠采样
 2. 过采样
 3. 阈值移动